Rincian Metrik Pengujian Sistem Virtual Barista Berbasis Modular RAG

Judul penelitian: Enhancing Specialty Coffee E-Commerce Services through a Modular RAG-Based Virtual Barista: A Case Study of 52 Coffee & Roastery

Status: rancangan untuk konsultasi metodologi; belum ada hasil pengujian final.

Tujuan pengujian

Pengujian dirancang untuk menilai fungsi website 52 Coffee & Roastery, kualitas jawaban Virtual Barista, pengendalian interaksi, kerja sama antarbagian sistem, kemungkinan penggunaan ulang komponennya, serta bantuan yang dirasakan pengguna. Penilaian manfaat pengguna merupakan usulan tambahan yang perlu dipastikan kesesuaiannya dengan tujuan skripsi bersama Pak Imam.

Rincian metrik

Metode pengujian	Metrik	Apa yang diukur	Cara menghitung / menilai
Black-Box Testing	Test Case Pass Rate	Proporsi kasus fungsi website yang memenuhi hasil yang diharapkan.	Kasus yang lulus dibagi seluruh kasus yang dijalankan (lulus dan gagal), lalu dinyatakan dalam persen. Kasus yang belum diuji dilaporkan terpisah.
Black-Box Testing	Requirement Coverage	Cakupan kebutuhan sistem yang benar-benar diperiksa.	Kebutuhan yang memiliki setidaknya satu kasus yang dijalankan dan bukti hasil dibagi seluruh kebutuhan dalam ruang lingkup, lalu dinyatakan dalam persen. Ini tidak sama dengan persentase kebutuhan yang lulus.
RAGAS Evaluation	Faithfulness	Apakah pernyataan dalam jawaban didukung informasi yang ditemukan sistem.	Penilai RAGAS membandingkan klaim jawaban dengan informasi yang digunakan; hasilnya berupa proporsi klaim yang didukung, pada skala 0–1.
RAGAS Evaluation	Answer Relevancy	Seberapa sesuai jawaban dengan pertanyaan pengguna.	RAGAS menilai kesamaan makna pertanyaan dan jawaban; hasilnya skor yang dapat berada antara −1 dan 1, bukan persentase kasus lulus. Jawaban relevan belum tentu benar secara fakta.
RAGAS Evaluation	Context Precision with Reference	Apakah informasi yang relevan muncul lebih awal di antara informasi yang ditemukan.	RAGAS menilai relevansi dan urutannya dengan membandingkan pertanyaan serta jawaban acuan; skor 0–1.
RAGAS Evaluation	Context Recall	Apakah informasi penting dalam jawaban acuan berhasil ditemukan.	RAGAS menilai bagian jawaban acuan yang didukung informasi hasil pencarian; skor 0–1.
NVIDIA NeMo Guardrails Testing	Violation Block Rate	Proporsi permintaan yang melanggar aturan dan berhasil ditolak.	Permintaan melanggar aturan yang ditolak dibagi seluruh permintaan melanggar aturan yang diuji, dalam persen. Hasil NeMo dan aturan tambahan aplikasi dicatat terpisah.
NVIDIA NeMo Guardrails Testing	False Rejection Rate	Seberapa sering pertanyaan sah keliru ditolak.	Pertanyaan sah yang salah ditolak dibagi seluruh pertanyaan sah yang diuji, dalam persen. Nilai lebih rendah lebih baik.
NVIDIA NeMo Guardrails Testing	Policy Compliance Rate	Kesesuaian keputusan akhir dengan aturan percakapan yang ditetapkan.	Skenario yang keputusan akhirnya sesuai aturan dibagi seluruh skenario sah, melanggar, dan di luar topik yang diuji, dalam persen.
Integration & Reusability Testing	Integration Test Pass Rate	Keberhasilan alur yang melibatkan beberapa bagian sistem.	Skenario integrasi yang lulus seluruh kriteria dibagi skenario integrasi yang dijalankan (lulus dan gagal), dalam persen; yang belum diuji dilaporkan terpisah.

Metode pengujian	Metrik	Apa yang diukur	Cara menghitung / menilai
Integration & Reusability Testing	Module Reuse Success Rate	Apakah komponen Virtual Barista dapat dipakai di sistem lain.	Skenario penggunaan ulang yang berhasil tanpa mengubah logika inti AI dibagi seluruh skenario penggunaan ulang yang dijalankan, dalam persen. Uji ini perlu mencakup antarmuka chatbot dan layanan AI, sesuai cakupan Bab I.
Comparative User Testing	Task Success Rate	Keberhasilan pengguna menyelesaikan tugas pada masing-masing kondisi website.	Tugas yang selesai dengan benar dibagi seluruh tugas yang dimulai pada kondisi tersebut, dalam persen. Orang yang sama mencoba website tanpa dan dengan Virtual Barista.
Comparative User Testing	Task Completion Time	Lama waktu pengguna menyelesaikan tugas.	Catat detik dari mulai sampai selesai atau batas waktu; bandingkan waktu kedua kondisi untuk peserta yang sama.
Comparative User Testing	Perceived Helpfulness	Seberapa membantu website menurut pengguna.	Setelah tiap tugas, peserta memberi nilai 1–5; bandingkan penilaian kedua kondisi untuk peserta yang sama.

Catatan penilaian: Skor yang tidak dapat dihitung dicatat sebagai tidak tersedia, bukan diberi nilai nol. Kualitas rekomendasi produk diperiksa tersendiri karena skor RAGAS tidak otomatis memastikan pilihan produknya tepat. Pada pengujian pengendalian interaksi, catat pula apakah NeMo benar-benar berjalan atau layanan sedang terganggu; keputusan aturan aplikasi tidak diklaim sebagai hasil NeMo.

Jumlah pengujian yang direncanakan

Metode	Jumlah	Cakupan singkat
Black-Box Testing	32 kasus	Fungsi website, katalog, keranjang, checkout simulasi, dan Virtual Barista.
RAGAS Evaluation	40 pertanyaan	10 informasi produk, 10 rekomendasi produk, 10 panduan/resep penyeduhan, 10 perbandingan produk.
NeMo Guardrails Testing	32 skenario	Pertanyaan sah, pelanggaran aturan, di luar topik, dan gangguan layanan.
Integration & Reusability Testing	7 + 3 skenario	Tujuh alur integrasi dan tiga percobaan penggunaan ulang komponen.
Comparative User Testing	24 + 4 orang	24 responden utama; empat peserta pilot terpisah untuk mencoba instrumen.

Pertanyaan

1. Apakah kelima metode dan metrik ini sudah sesuai dengan rumusan masalah dan tujuan penelitian, khususnya pengujian manfaat pengguna sebagai tambahan?
2. Apakah jumlah kasus, pertanyaan, skenario, dan responden yang direncanakan sudah memadai?
3. Apakah tiap metrik memerlukan batas nilai keberhasilan? Jika ya, dasar apa yang sebaiknya digunakan sebelum pengujian final?

Status dan batas kesimpulan

Dataset dan instrumen masih disiapkan; pengujian final belum dilakukan. Metode pembayaran final masih dalam pembahasan dengan owner 52 Coffee & Roastery. Transfer bank dan QRIS tertulis dalam Bab I sebagai rencana awal, tetapi belum menjadi keputusan bisnis final; checkout yang tersedia saat ini masih simulasi. Karena itu, pengujian belum dapat menyimpulkan keberhasilan pembayaran nyata atau peningkatan penjualan. Cakupan pengujian pembayaran perlu disesuaikan setelah keputusan owner disepakati dengan pembimbing.